

TutorLLM: 基于知识追踪和检索增强生成技术定制学习推荐

赵兴 LI

zhaoxing.li@soton.ac.uk
南安普敦大学 南安普敦, 英国

瓦希德·亚兹丹帕纳赫 金迪·王 南安普敦大学 杜伦大学 南

安普敦, 英国 杜伦, 英国 v.yazdanpanah@soton.ac.uk
jindi.wang@durham.ac.uk

郭文 日本先进科学技术院 野
米, 日本 wgu@jaist.ac.jp

石雷 亚历山德拉·I·克里斯蒂亚 新城堡大学 杜伦大学 新城堡,
英国 杜伦, 英国 lei.shi@newcastle.ac.uk
alexandra.i.cristea@durham.ac.uk

莎拉·基登 南安普敦
大学 南安普敦, 英国
sk3r24@soton.ac.uk

Sebastian Stein 大
学 萨里大学 萨里, 英国
ss2@ecs.soton.ac.uk

摘要

人工智能在教育领域的融合为提升学习效率提供了重要潜力。大型语言模型 (LLM), 如ChatGPT、Gemini和Llama, 允许学生查询广泛的主题, 提供了前所未有的灵活性。然而, LLM面临着挑战, 例如处理不同内容的相关性和缺乏个性化。为了应对这些挑战, 我们提出了TutorLLM, 一个基于知识追踪 (KT) 和检索增强生成 (RAG) 的个性化学习推荐 LLM系统。TutorLLM的独特之处在于其将KT和RAG技术与 LLM相结合, 能够动态检索特定上下文的知识, 并根据学生的个人学习状态提供个性化学习推荐。具体而言, 这种融合使TutorLLM能够根据多特征与潜在关系BERT模型 (MLFBK) 预测的个体学习状态调整响应, 并通过Scraper模型提高响应的准确性。评估包括用户问卷调查和性能指标, 与单独使用通用LLM相比, 用户满意度提高了10%, 测验分数提高了5%。

CCS 概念

• 应用计算 → 在线学习; • 计算方法论
gies → 人工智能。

允许为个人或课堂教学目的免费制作本文的全部或部分数字或纸质副本, 但前提是副本不得以营利或商业优势为目的制作或分发, 并且副本应包含本声明并在首页标明完整引用信息。本文中由作者以外的其他人拥有的组件的版权必须得到尊重。经注明出处后允许摘录。否则复制或再出版、在服务器上发布或重新分发到列表中, 需要事先获得特定许可和/或支付费用。请向 permissions@acm.org 申请许可。RecSys 2024, 2024年10月14日至18日, 意大利巴里 © 2024 版权所有/作者。出版许可给 ACM。ACM ISBN 978-1-4503-XXXX-X/18/06...\$15.00
<https://doi.org/XXXXXXX.XXXXXXX>

关键词

学习推荐系统、大语言模型、个性化学习、知识追踪

ACM 参考格式:

赵兴 LI, 瓦希德·亚兹丹帕纳赫, 金迪·王, 温古, 石雷, 亚历山德拉·I·克里斯蒂亚, 莎拉·基登, 以及 塞巴斯蒂安·施泰因. 2024. TutorLLM: 基于知识追踪和检索增强生成的个性化学习推荐. 在第 18 届 ACM 推荐系统会议 (RecSys 2024) 论文集. ACM, 纽约, NY, USA, 6 页.
<https://doi.org/XXXXXXX.XXXXXXX>

1 引言

人工智能技术正日益影响日常生活的各个方面, 尤其是在教育环境中。人工智能为提升学生的学习过程和效率提供了重大机遇。在这些人工智能应用中, 大型语言模型 (LLM) 尤为突出, 例如ChatGPT1、Gemini 2和Llama 3, 它们允许学生查询广泛的主题, 从而在学习中提供了前所未有的灵活性。与传统搜索引擎不同, LLM使学生能够提出细致和复杂的问题, 进行对话式交互, 并通过后续问题寻求澄清, 从而增强了学习体验的深度和有效性。尽管有这些优势, 当前的 LLM仍面临一些挑战。这些挑战包括生成不准确的信息 (通常被称为“幻觉”)、缺乏个性化以及内容相关性的变化 [1, 10, 35]。具体来说, 这些模型在处理需要高级逻辑和数学问题时往往存在困难, 例如解决复杂方程式或提供逐步的逻辑推理, 并且无法根据个人学习水平调整响应, 有时会提供过于笼统的答案或需要大量提示才能提供有用信息 [35]。

¹<https://chatgpt.com/>

²<https://gemini.google.com/app>

³<https://llama.meta.com/>

相比之下, 传统的教育推荐系统利用知识追踪 (KT) 等技术来跟踪学生的学习轨迹并提供个性化推荐。KT方法利用历史交互数据来预测未来的学习行为 [9]。尽管这些系统具有实用性, 但与LLM相比, 它们在语言多样性和适应性方面往往存在不足。它们的响应通常局限于其数据库中的预定义集合, 限制了它们动态响应更广泛查询的能力 [35]。这种局限性限制了系统实时适应个人学习需求的能力, 从而降低了教育体验的有效性和参与度。

为弥合大语言模型 (LLM) 的适应性教育与推荐系统个性化方法之间的差距, 我们提出了一种基于知识追踪 (KT) 和检索增强生成 (RAG) 的新型框架: 个性化教育推荐LLM系统 (TutorLLM)。据我们所知, 我们是首批将KT技术融入LLM以实现个性化推荐学习框架的研究者。TutorLLM包含三个核心组件。第一个组件是KT模型, 该模型基于多特征与潜在关系BERT知识追踪 (MLFBK) 模型 [16]开发。该组件不仅收集学生互动和表现数据, 还整合与LLM对话的信息, 为学生能力、学习状态以及所学知识的复杂性提供洞察。第二个组件是Scraper。该组件在在线学习过程中收集文本内容, 以提供与上下文相关的背景知识, 从而提高LLM响应的相关性和准确性。第三个组件是RAG增强LLM。该组件利用GPT-4 API, 整合Scraper和KT模块的输入, 以提供精确、个性化的响应和学习内容推荐。此外, 为了实现更个性化的交互, 学生可以手动上传学习材料。图1展示了该架构的整体模型。Scraper提供的文本内容通过动态检索和整合相关课程材料中的上下文特定知识来缓解幻觉, 确保信息的准确性和可靠性。此外, 知识追踪的集成使TutorLLM能够提供高度个性化的推荐和响应, 根据每个学生的学习进度和需求进行定制。

为实施和评估这一综合方法, 我们开发了一个 Chrome 浏览器插件, 作为学生直接与 TutorLLM 交互的界面。学生可以在在线学习过程中向 TutorLLM 提问。课程结束后, TutorLLM 将为学生提供个性化的学习资料推荐。学生可以根据这些推荐决定是否进一步学习。我们的评估涉及对在线线性代数课程中的 30 名本科生进行的为期两周的实地研究, 采用交叉设计来比较通用 LLM 方法和 TutorLLM 的有效性和用户满意度。结果显示, 与通用 LLM 方法相比, TutorLLM 用户的用户满意度通过系统可用性量表 (SUS) 测量, 提高了 10%, 学业表现基于测验分数, 提高了 5%。

2 相关工作

大型语言模型 (LLM), 凭借其先进的自然语言处理 (NLP) 和理解 (NLU) 能力, 已显著影响了包括教育在内的各个领域 [12]。这些模型在大量文本数据上进行训练, 能够生成类人文本、理解复杂查询并提供详细解释 [5]。例如, OpenAI 的 GPT-3 和 GPT-4 等模型被用于教育工具, 用于辅导、回答问题 and 生成学习资料 [4, 8]。然而, LLM 可能会产生错误或误导性信息 (“幻觉”), 通常缺乏针对个人用户学习水平的个性化回应, 有时还需要大量提示才能变得有用 [29, 35]。

教育推荐系统通过根据学生的需求、偏好和进度定制教育内容, 提供个性化的学习体验 [26]。传统系统使用协同过滤、基于内容的过滤或混合方法来推荐相关资源。将这些系统与 LLM 和 KT 模型等 AI 技术相结合, 可以显著提升学习成果的个性化和性能 [6, 31–34, 36]。

知识追踪通过跟踪学生与学习材料和评估的互动, 监测和预测学生的知识状态随时间的变化 [9, 25]。它支持个性化推荐和有针对性的干预措施, 以弥补学生的知识差距。贝叶斯知识追踪 (BKT) [24] 和深度知识追踪 (DKT) [25] 等传统方法在教育推荐系统中被广泛使用, 利用历史数据来预测未来的表现和学习需求 [22, 23]。近期模型, 如多特征与潜在关系 BERT 知识追踪 (MLFBK), 提升了预测的准确性和深度 [7, 13, 15–21, 28]。

3 OFTUTORLLM 实现

TutorLLM 由三个主要组件构成: 用于收集教育内容的抓取模型、用于预测学生学习状态的 KT, 以及基于 RAG 的 LLM, 用于动态检索信息并定制个性化回复。

总体方法论。我们方法的主要动机是使大型语言模型能够理解学生的学习状态 (或知识掌握状态), 以及正在进行的课程的具体内容, 从而提供情境化响应和定制化的学习内容推荐。因此, 我们的方法分为三个不同的组件。首先, KT 组件利用算法追踪学生的学习状态。这包括追踪技能掌握程度、能力画像、问题难度, 并预测学生最有可能的下一步行动。在这个组件中, 我们采用 MLFBK 作为 KT 方法。其次, Scraper 功能旨在从在线课程平台收集和整理文本信息, 包括嵌入网页中的视频的标题和字幕, 并将其整理到背景知识库中。在从 KT 组件接收学生行为序列数据后, TutorLLM 首先综合学生的当前学习状态, 重点在于识别薄弱知识领域并预测学生的潜在下一步行动。最后, 模型根据背景知识库和学生们的学习状态提供个性化答案和推荐。此外, 模型会在学生请求或每次学习会话后推荐额外的学习材料。基于以上思路, 我们构建了一个 Chrome 浏览器插件。当学生打开在线课程网站时, 他们可以通过点击地址栏右侧的按钮打开我们的 TutorLLM。图2展示了 TutorLLM 的界面。下面将详细介绍这三个组件的功能:




图1: TutorLLM的整体架构

基于以上想法, 我们构建了一个Chrome浏览器插件。当学生打开在线课程网站时, 他们可以通过点击地址栏右侧的按钮打开我们的TutorLLM。图2展示了TutorLLM的界面。下面将详细介绍这三个组件的功能:

抓取模型: TutorLLM的抓取组件是为了自主收集和组织在线课程网页中的文本内容而开发的。它提取文本信息, 包括关键的标题和字幕, 以构建丰富的背景知识库。该功能基于Jina AI的Reader API⁴构建。在运行时, 抓取组件作为Chrome插件动态与教育网站交互, 由学生激活。当访问相关页面时, 抓取组件处理内容, 将统一资源定位符(URL)转换为LLM友好的输入, 包括结构化文本和上下文标题。这确保了每一段提取的内容都经过优化, 以供大型语言模型使用, 提供准确、最新的信息, 反映课程材料的当前范围。

知识追踪模型: 在知识追踪部分, 我们使用MLFBK[16]来整合多特征嵌入和潜在关系, 以捕捉学生的学习状态。MLFBK由三个部分组成: 嵌入、基于BERT的架构和正确性序列输出。

在嵌入部分中, 有两个组件: 多特征嵌入和潜在关系嵌入。在多特征嵌入组件中, 集成了四个不同的特征, 包括学生_id、技能_id、问题_id和响应_id。潜在关系嵌入组件采用特征工程方法提取三个重要关系: 技能掌握、能力画像和问题难度。技能掌握基于贝叶斯知识追踪建模, 而能力画像使用不同时间间隔的过去表现进行编码, 并通过K-means算法 [27]更新。问题难度在1到10的量表上量化 (其中1表示简单, 10表示极其困难),

⁴<https://github.com/jina-ai/reader>




图2: TutorLLM的用户界面。

基于成功率。此外, 整体模型集成涵盖了问题、项目、响应、技能掌握、能力画像和问题难度嵌入等组合, 最终形成最终的输入嵌入。

在基于BERT的架构中, 编码器模块利用预LN Transformer架构 [29], 该架构包含单调卷积多头注意力机制, 随后接全连接层并使用LeakyReLU激活函数。单调多头注意力机制与混合注意力及单调注意力结合使用, 用于序列数据的表示。

在正确性序列输出部分, 我们首先获取关于学生序列动作数据的预测。随后, 预测动作将追加到学生历史动作序列的末尾, 生成完整的输出序列。

RAG大型语言模型: 该大型语言模型组件由GPT-4 API提供支持, 采用检索增强生成 (RAG) [14] 方法生成回复。

模型激活时, 会从知识追踪组件接收经过处理的输入, 其中包含关于学生对各项技能当前掌握程度以及预测的下一步行动的详细见解。检索过程始于模型查询由Scraper模型从在线课程材料中填充的背景知识库。这确保了回复不仅基于通用信息, 还融入了最新的、课程特定的内容, 从而提高学习效果。

大型语言模型随后将知识库中的信息与学生特定的学习情境相结合, 生成回复。这些回复可能包括直接回答查询、解释复杂主题或提供解决问题的提示。此外, 模型会根据学生的学习进度和困难领域主动提供学习建议, 这可能包括建议复习某些主题或根据学生的准备情况前进到新内容。

4 用户研究

参与者和研究设置。 为了评估 TutorLLM 教育工具对学生学习成果的有效性, 来自南安普顿大学线性代数课程的首届本科生共 30 名被随机分配到三个实验组中的一个进行受控实验。对照组在整个研究期间仅使用通用 LLM (chatGPT4 的通用网络版本)。实验组 1 在第一周接触通用 LLM, 第二周使用 TutorLLM, 而实验组 2 在两周内始终使用 TutorLLM。主要目标在于确定整合 TutorLLM 是否能比通用 LLM 提升学习表现。

学生表现。 在两周内, 学生每天探索线性代数的新内容。他们利用我们的 TutorLLM 每天在学习中解决疑问。课程结束时, TutorLLM 会建议相关的教育资源和学习练习。学生可以自行决定是否参与这些额外材料, 而对照组使用通用 LLM 模型且不接收此类建议。每天结束时进行测验, 检验所学知识, 最终在两周结束时进行涵盖所有主题的综合考试。评估框架包括 15 次测试, 每次日常测验包含 10 道题, 最高可得 100 分。这些日常测验和最终的综合考试共同决定了学生的整体表现。

用户研究。 对1组和2组的学生进行了问卷调查, 以评估 TutorLLM 的有效性及其对学生满意度的影响。该调查的设计旨在

收集学生使用TutorLLM的定量和定性数据。调查设计包括一个系统可用性量表 (SUS) [2] 和一个用户体验 (UX) [30] 问卷, 以提供全面的评估。SUS是一个经过验证的工具, 用于衡量用户对可用性的感知, 重点关注用户友好性和可理解性, 较高的SUS分数表明界面更直观, 用户控制力更强。用户体验从三个角度进行测量, 分别是用户满意度 (US)、舒适度 (CL) 和继续意愿 (CW)。用户满意度使用5点李克特量表进行评估, 以衡量对工具的整体满意度, 积极的US分数反映了助手在有用性和响应性方面满足或超出用户期望的能力。舒适度在5点量表上评分, 以衡量用户在在线平台进行初始文本交互时的舒适度, 为优化聊天界面和提升交互体验提供关键洞察 [3]。继续意愿在5点量表上测量, 捕捉用户在初始对话后继续交互的意愿 [11]。

5 个结果

测试结果。 我们通过15次测试 (包括最终考试) 评估了三个对照组学生的表现。这些组分别使用了通用LLM、混合LLM方法和TutorLLM。初步分析显示, TutorLLM组获得了最高的平均分74.48, 其次是混合LLM组的72.81和通用LLM组的71.97。为了确定不同组别在最终考试成绩差异上的统计学意义, 我们进行了方差分析 (ANOVA)。该分析得出F统计量为0.795, p值为0.462, 表明各组间表现无显著差异。图3展示了每个研究组的每日平均分。尽管差异未达到统计学意义, 但TutorLLM组的表现显示出明显的提升趋势。这些结果表明, 需要进一步研究, 可能涉及更大的样本量、不同的研究设计或更长的测试时间, 才能最终确定集成TutorLLM提升学业表现的有效性。




图 3: 不同学习组用户表现的平均日分数

可用性和用户体验。从可用性角度来看, SUS结果表明用户体验总体积极, 平均SUS得分为76.35, 中位数为79, 反映了高可用性。得分显示出中等变异性, 标准差为14.46, 多数得分在61.89至90.81之间, 表明评价的一致性。Shapiro-Wilk检验证实了得分分布的正态性 ($p = 0.721$), 支持了可用性评估的有效性。自举分析估计中位数的95%置信区间在68.5至83之间, 进一步验证了用户对TutorLLM可用性的积极反馈。

从用户体验角度来看, CL、CW和US的分析显示, CL、CW和US的平均得分分别为3.50、3.40和3.61, 相应的标准差为1.00、0.99和0.82。相关性分析揭示了CL和CW之间0.53的中度正相关、CL和US之间0.45的中度正相关以及CW和US之间0.40的中度正相关, 这表明用户对应用程序感觉更舒适、更满意, 也更愿意继续使用它。

6 讨论

虽然我们的研究没有显示TutorLLM在学术表现上有统计学上的显著提升, 但参与度和平均得分的提高表明其潜在益处。我们监测了学生对LLM的使用时长。与使用通用LLM的学生相比, TutorLLM用户在系统中投入的时间增加了36%。这种参与度的提高表明学生对TutorLLM更满意, 更愿意投入额外时间。此外, TutorLLM推荐的学习材料在一定程度上对学生的表现产生了积极影响。这些发现强调了进一步优化AI驱动教育工具以更好地适应个体学习需求和背景的重要性。它也可能重新定义个性化学习, 通过定制内容和智能响应系统使教育互动更有效、更具吸引力。

7 结论

在本文中, 我们介绍了TutorLLM, 这是一个将大型LLM与KT和RAG相结合以增强个性化学习的新框架。我们的主要贡献包括首次将LLM与KT结合以提高个性化。我们通过Chrome浏览器插件展示了TutorLLM的实际应用, 并在为期两周的大学生研究中验证了其有效性。未来的研究应专注于改进TutorLLM的个性化功能, 测试其在不同学科中的有效性, 并解决集成现有技术、确保数据隐私以及提供教师培训等挑战。

参考文献

- [1] Razvan Azamfirei, Sapna R Kudchadkar, and James Fackler. 2023. Large language models and the perils of their hallucinations. *Critical Care* 27, 1 (2023), 120.
- [2] Aaron Bangor, Philip T Kortum, and James T Miller. 2008. An empirical evaluation of the system usability scale. *Intl. Journal of Human-Computer Interaction* 24, 6 (2008), 574–594.
- [3] Susan Bergin and Ronan Reilly. 2005. The influence of motivation and comfort-level on learning to program. (2005).

- [4] Tom B Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. 2020. Language models are few-shot learners. *Advances in neural information processing systems* 33 (2020), 1877–1901.
- [5] Yupeng Chang, Xu Wang, Jindong Wang, Yuan Wu, Linyi Yang, Kaijie Zhu, Hao Chen, Xiaoyuan Yi, Cunxiang Wang, Yidong Wang, et al. 2024. A survey on evaluation of large language models. *ACM Transactions on Intelligent Systems and Technology* 15, 3 (2024), 1–45.
- [6] Hsinchun Chen, Roger HL Chiang, and Veda C Storey. 2020. Big data analytics for educational recommender systems: A review and research agenda. *MIS quarterly* 44, 1 (2020), 135–169.
- [7] Jiahao Chen, Zitao Liu, Shuyan Huang, Qiongqiong Liu, and Weiqi Luo. 2023. Improving interpretability of deep sequential knowledge tracing models with question-centric cognitive representations. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 37. 14196–14204.
- [8] Tsung-Hsien Chen, Minghao Li, Ying-Hsun Chien, et al. 2021. A survey of large language models. *arXiv preprint arXiv:2109.11601* (2021).
- [9] Albert T Corbett and John R Anderson. 1994. Knowledge tracing: Modeling the acquisition of procedural knowledge. *User modeling and user-adapted interaction* 4, 4 (1994), 253–278.
- [10] Luciano Floridi and Massimo Chiriatti. 2020. GPT-3: Its nature, scope, limits, and consequences. *Minds and Machines* 30, 4 (2020), 681–694.
- [11] Mark Freiermuth and Douglas Jarrell. 2006. Willingness to communicate: can online chat help? 1. *International journal of applied linguistics* 16, 2 (2006), 189–212.
- [12] Tiffany H Kung, Morgan Cheatham, Arielle Medenilla, Czarina Sillos, Lorie De Leon, Camille Elepaño, Maria Madriaga, Rimel Aggabao, Giezel Diaz-Candido, James Maningo, et al. 2023. Performance of ChatGPT on USMLE: potential for AI-assisted medical education using large language models. *PLoS digital health* 2, 2 (2023), e0000198.
- [13] Unggi Lee, Yonghyun Park, Yujin Kim, Seongyune Choi, and Hyeoncheol Kim. 2022. MonaCoBERT: Monotonic attention based ConvBERT for Knowledge Tracing. *arXiv preprint arXiv:2208.12615* (2022).
- [14] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Kuttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, et al. 2020. Retrieval-augmented generation for knowledge-intensive nlp tasks. *Advances in Neural Information Processing Systems* 33 (2020), 9459–9474.
- [15] Zhaoxing Li. 2023. *Deep Reinforcement Learning Approaches for Technology Enhanced Learning*. Ph.D. Dissertation. Durham University.
- [16] Zhaoxing Li, Mark Jacobsen, Lei Shi, Yunzhan Zhou, and Jindi Wang. 2023. Broader and Deeper: A Multi-Features with Latent Relations BERT Knowledge Tracing Model. In *European Conference on Technology Enhanced Learning*. Springer, 183–197.
- [17] Zhaoxing Li, Lei Shi, Alexandra I Cristea, and Yunzhan Zhou. 2021. A survey of collaborative reinforcement learning: interactive methods and design patterns. In *Proceedings of the 2021 ACM Designing Interactive Systems Conference*. 1579–1590.
- [18] Zhaoxing Li, Lei Shi, Jindi Wang, Alexandra I Cristea, and Yunzhan Zhou. 2023. Sim-GAIL: A generative adversarial imitation learning approach of student modelling for intelligent tutoring systems. *Neural Computing and Applications* 35, 34 (2023), 24369–24388.
- [19] Zhaoxing Li, Lei Shi, Yunzhan Zhou, and Jindi Wang. 2023. Towards student behaviour simulation: a decision transformer based approach. In *International Conference on Intelligent Tutoring Systems*. Springer, 553–562.
- [20] Zhaoxing Li, Jujie Yang, Jindi Wang, Lei Shi, Jiayi Feng, and Sebastian Stein. 2024. Lbkt: a lstm bert-based knowledge tracing model for long-sequence data. In *International Conference on Intelligent Tutoring Systems*. Springer, 174–184.
- [21] Zhaoxing Li, Jujie Yang, Jindi Wang, Lei Shi, and Sebastian Stein. 2024. Integrating LSTM and BERT for Long-Sequence Data Analysis in Intelligent Tutoring Systems. *arXiv preprint arXiv:2405.05136* (2024).
- [22] Qi Liu, Shuanghong Shen, Zhenya Huang, Enhong Chen, and Yonghe Zheng. 2021. A survey of knowledge tracing. *arXiv preprint arXiv:2105.15106* (2021).
- [23] Himanshu Pandey and Rajesh Kumar Pandey. 2019. Machine learning based approaches for personalized recommender system: A survey. *Procedia computer science* 165 (2019), 551–559.
- [24] Radek Pelánek. 2017. Bayesian knowledge tracing, logistic models, and beyond: an overview of learner modeling techniques. *User modeling and user-adapted interaction* 27 (2017), 313–350.
- [25] Chris Piech, Joe Bassen, Jonathan Huang, Surya Ganguli, Mehran Sahami, Leonidas Guibas, and Jascha Sohl-Dickstein. 2015. Deep knowledge tracing. *Advances in neural information processing systems* 28 (2015).
- [26] Francesco Ricci, Lior Rokach, Bracha Shapira, et al. 2011. Introduction to recommender systems handbook. *Recommender systems handbook* (2011), 1–35.
- [27] Douglas Steinley. 2006. K-means clustering: a half-century synthesis. *Brit. J. Math. Statist. Psych.* 59, 1 (2006), 1–34.
- [28] Zejie Tian, Guangcong Zheng, Brendan Flanagan, Jiazhi Mic, and Hiroaki Ogata. 2021. BEKT: Deep Knowledge Tracing with Bidirectional Encoder Representations from Transformers. In *Proceedings of the 29th International Conference on Computers in Education*.

- [29] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. *Advances in neural information processing systems* 30 (2017).
- [30] Arnold POS Vermeeren, Effie Lai-Chong Law, Virpi Roto, Marianna Obrist, Jettie Hoonhout, and Kaisa Väänänen-Vainio-Mattila. 2010. User experience evaluation methods: current state and development needs. In *Proceedings of the 6th Nordic conference on human-computer interaction: Extending boundaries*. 521–530.
- [31] Jindi Wang, Ioannis Ivrissimtzis, Zhaoxing Li, and Lei Shi. 2024. Comparative Efficacy of 2D and 3D Virtual Reality Games in American Sign Language Learning. In *The 31st IEEE Conference on Virtual Reality and 3D User Interfaces*. Newcastle University.
- [32] Jindi Wang, Ioannis Ivrissimtzis, Zhaoxing Li, and Lei Shi. 2024. Enhancing User Experience in Chinese Initial Text Conversations with Personalised AI-Powered Assistant. In *Extended Abstracts of the CHI Conference on Human Factors in Computing Systems* (<conf-loc>, <city>Honolulu</city>, <state>HI</state>, <country>USA</country>, </conf-loc>) (CHI EA '24). Association for Computing Machinery, New York, NY, USA, Article 129, 7 pages. <https://doi.org/10.1145/3613905.3651104>
- [33] Jindi Wang, Ioannis Ivrissimtzis, Zhaoxing Li, and Lei Shi. 2024. Impact of Personalised AI Chat Assistant on Mediated Human-Human Textual Conversations: Exploring Female-Male Differences. In *Companion Proceedings of the 29th International Conference on Intelligent User Interfaces*. 78–83.
- [34] Jindi Wang, Ioannis Ivrissimtzis, Zhaoxing Li, Yunzhan Zhou, and Lei Shi. 2023. Exploring the Potential of Immersive Virtual Environments for Learning American Sign Language. In *European Conference on Technology Enhanced Learning*. Springer, 459–474.
- [35] Lixiang Yan, Lele Sha, Linxuan Zhao, Yuheng Li, Roberto Martinez-Maldonado, Guanliang Chen, Xinyu Li, Yueqiao Jin, and Dragan Gašević. 2024. Practical and ethical challenges of large language models in education: A systematic scoping review. *British Journal of Educational Technology* 55, 1 (2024), 90–112.
- [36] Shuai Zhang, Lina Yao, Aixin Sun, and Yi Tay. 2019. Deep learning based recommender system: A survey and new perspectives. *ACM computing surveys (CSUR)* 52, 1 (2019), 1–38.